超越独立性的集成投票

Part I 与 Part II 的严格数学证明

2026 年 10 月

摘要

本文研究 K（奇数）个二分类器的多数投票准确率 $A = \mathbb{P}(S \geq m)$，其中 S 为正确分类器个数，$m = (K+1)/2$。

1. **Part I**。在独立情形下给出 Condorcet 型结论及其精确增量公式；在只知道各分类器准确率、依赖结构任意的情形下，给出多数投票准确率的*紧确*下界与上界：相同准确率时是闭式（定理 3.3），不同准确率时是关于排序后部分和的闭式（定理 4.1），并显式构造达到界的联合分布。
2. **Part II**。证明“边缘准确率 + 全部两两相关系数”一般不能唯一确定多数投票准确率。$K = 3$ 时给出准确率可行区间的完整闭式解（定理 5.2、推论 5.3）以及参数相容的充要条件；一般 K 时将问题写成线性规划，并证明对称情形可约化为 $K+1$ 个变量，且存在至多 3 个非零分量的最优解（命题 5.8）。

定理 3.3、4.1、5.2、推论 5.3 和命题 5.8 都在随机参数下与穷举 $\{0,1\}^K$ 的线性规划做过数值核对，差值不超过 10^{-11}。第 6 节说明各结论与已有文献的关系：Part I 的结论均为已知结论，本文给出自包含的证明。

目录

1 问题设定与记号 2

2 Part I(a)：独立情形 2

3 Part I(b)：相同准确率、依赖任意 4

4 Part I(c)：不同准确率、依赖任意 5

5 Part II：给定两两相关系数 7

6 与已有文献的关系 11

7 结论汇总 12

1 问题设定与记号

定义 1.1（基本设定） 设标签 $Y \in \{0,1\}$，输入为 X，有 K 个分类器 $f_1, \dots, f_K$，其中 $K \geq 1$ 为奇数。记

$$Z_i = \mathbf{1}\{f_i(X) = Y\} \in \{0,1\}, \qquad p_i = \mathbb{P}(Z_i = 1), \qquad S = \sum_{i=1}^{K} Z_i, \qquad m = \frac{K+1}{2}.$$

多数投票分类器 $\mathrm{MV}(X)$ 输出得票数至少为 m 的那个标签。由于 K 为奇数且只有两个标签，该标签唯一。

引理 1.2 $\mathrm{MV}(X) = Y$ 当且仅当 $S \geq m$。因此集成准确率为

$$A = \mathbb{P}(\mathrm{MV}(X) = Y) = \mathbb{P}(S \geq m).$$

证明. 正确的分类器投给 Y，错误的分类器投给 $1-Y$。所以 Y 得 S 票，$1-Y$ 得 $K-S$ 票。K 为奇数，不会平票。Y 胜出当且仅当 $S > K - S$，即 $S \geq (K+1)/2 = m$。 □

因此 A 只依赖于随机向量 $Z = (Z_1, \dots, Z_K)$ 在 $\{0,1\}^K$ 上的分布 π。记

$$\mathcal{P}(p) = \big\{\pi \text{ 为 } \{0,1\}^K \text{ 上的概率分布：} \mathbb{P}_\pi(Z_i = 1) = p_i,\ i = 1, \dots, K\big\},$$
$$A_-(p) = \inf_{\pi \in \mathcal{P}(p)} \mathbb{P}_\pi(S \geq m), \qquad A_+(p) = \sup_{\pi \in \mathcal{P}(p)} \mathbb{P}_\pi(S \geq m).$$

$\mathcal{P}(p)$ 是 $\mathbb{R}^{2^K}$ 中的非空紧凸多面体（独立分布总在其中），目标函数线性，所以上下确界都能取到。下文每个界都会给出显式的取到它的分布。

注 1.3（可实现性） 上面的极值是在 $\{0,1\}^K$ 上*所有*分布中取的。要说“极值分布可以由真实的确定性分类器实现”，需要数据分布足够丰富。一个充分条件是：$Y = g(X)$ 几乎处处成立（无标签噪声），且 X 的分布无原子。此时由无原子测度的介值性质（Sierpiński 定理），对任意 π 可以把输入空间划分为可测集 $\{B_z\}_{z \in \{0,1\}^K}$，使 $\mathbb{P}(X \in B_z) = \pi(z)$。令 $x \in B_z$ 时 $f_i(x) = g(x)$（若 $z_i = 1$）或 $1 - g(x)$（若 $z_i = 0$），即得 $Z = z$ 当且仅当 $X \in B_z$。若数据分布不满足这一条件，本文给出的界仍然成立，只是未必能取到。

2 Part I(a)：独立情形

定理 2.1 若 $Z_1, \dots, Z_K$ 独立同分布于 $\mathrm{Bernoulli}(p)$，则 $S \sim \mathrm{Bin}(K, p)$，且

$$A_{\mathrm{ind}}(K, p) = \sum_{j=m}^{K} \binom{K}{j} p^j (1-p)^{K-j}.$$

证明. 由独立性和引理 1.2 直接得到。 □

定理 2.2（Condorcet 陪审团定理） 记 $q = 1 - p$，$K = 2r + 1$。

(i) 增量公式：

$$A_{\text{ind}}(K+2,p) - A_{\text{ind}}(K,p) = \binom{2r+1}{r} p^{r+1} q^{r+1} \,(2p-1).$$

因此当 $1/2 < p < 1$ 时 $A_{\text{ind}}(K,p)$ 关于奇数 K 严格递增；当 $0 < p < 1/2$ 时严格递减；当 $p \in \{0, 1/2, 1\}$ 时不随 K 改变。

(ii) 极限：

$$\lim_{K\to\infty} A_{\text{ind}}(K,p) = \begin{cases} 1, & p > 1/2, \\ 1/2, & p = 1/2, \\ 0, & p < 1/2, \end{cases}$$

更精确地，

$$1 - A_{\text{ind}}(K,p) \le e^{-2K(p-1/2)^2} \;\; (p > 1/2), \qquad A_{\text{ind}}(K,p) \le e^{-2K(1/2-p)^2} \;\; (p < 1/2).$$

证明. (i) 设 $S_K \sim \text{Bin}(K,p)$，$W = Z_{K+1} + Z_{K+2} \sim \text{Bin}(2,p)$，二者独立。$K+2$ 个分类器的多数阈值为 $m+1$，所以

$$A_{\text{ind}}(K+2,p) - A_{\text{ind}}(K,p) = \mathbb{P}(S_K + W \ge m+1) - \mathbb{P}(S_K \ge m).$$

按 S_K 的取值分情况：

- $S_K \le m-2$ 时两个事件都不发生；
- $S_K \ge m+1$ 时两个事件都发生；
- $S_K = m-1$ 时旧事件不发生，新事件发生当且仅当 $W = 2$；
- $S_K = m$ 时旧事件发生，新事件不发生当且仅当 $W = 0$。

所以差值等于

$$\mathbb{P}(S_K = m-1)\, p^2 - \mathbb{P}(S_K = m)\, q^2 = \binom{K}{r} p^r q^{r+1} p^2 - \binom{K}{r+1} p^{r+1} q^r q^2,$$

这里用了 $m - 1 = r$。由 $\binom{2r+1}{r} = \binom{2r+1}{r+1}$，上式等于 $\binom{2r+1}{r} p^{r+1} q^{r+1} (p-q)$，而 $p - q = 2p - 1$。单调性结论由 $(2p-1)$ 的符号得到。

(ii) Hoeffding 不等式 [3] 给出：对 $t > 0$，$\mathbb{P}(S/K - p \le -t) \le e^{-2Kt^2}$，$\mathbb{P}(S/K - p \ge t) \le e^{-2Kt^2}$。

当 $p > 1/2$ 时，$\{S \le m-1\} \subseteq \{S/K < 1/2\} = \{S/K - p < -(p - \frac{1}{2})\}$，于是 $1 - A_{\text{ind}} = \mathbb{P}(S \le m-1) \le e^{-2K(p-1/2)^2}$。

当 $p < 1/2$ 时，$\{S \ge m\} \subseteq \{S/K - p > \frac{1}{2} - p\}$，于是 $A_{\text{ind}} \le e^{-2K(1/2-p)^2}$。

当 $p = 1/2$ 时，$K - S$ 与 S 同分布，且 $\{S \ge m\}$ 与 $\{K - S \ge m\} = \{S \le m-1\}$ 构成 Ω 的划分，所以两者的概率都是 $1/2$。 □

3 Part I(b)：相同准确率、依赖任意

本节设 $p_1 = \cdots = p_K = p$，记 $A_-(K,p)$、$A_+(K,p)$。

定义 3.1（均匀 s-子集分布） 对 $s \in \{0,1,\dots,K\}$，令 μ_s 为在 $\binom{K}{s}$ 个恰含 s 个 1 的向量上的均匀分布。在 μ_s 下 $S \equiv s$，且由对称性

$$\mathbb{P}_{\mu_s}(Z_i = 1) = \frac{s}{K}, \qquad \mathbb{P}_{\mu_s}(Z_i = Z_j = 1) = \frac{s(s-1)}{K(K-1)} \quad (i \neq j).$$

对权重 $w_s \geq 0$，$\sum_s w_s = 1$，混合分布 $\sum_s w_s \mu_s$ 满足：$\mathbb{P}(Z_i = 1) = \mathbb{E}[S]/K$ 对每个 i 相同，且 $\mathbb{P}(S \geq m) = \sum_{s \geq m} w_s$。这类分布称为*可交换分布*。

引理 3.2（数票不等式） 对任意 π（不要求边缘相同），记 $B = \{S \geq m\}$，$A = \mathbb{P}(B)$，则

$$m\,A \;\leq\; \mathbb{E}[S] \;\leq\; (m-1) + (K-m+1)\,A.$$

证明. 在 B 上 $m \leq S \leq K$，在 B^c 上 $0 \leq S \leq m-1$，所以逐点地有 $m\mathbf{1}_B \leq S \leq K\mathbf{1}_B + (m-1)\mathbf{1}_{B^c}$。取期望，并利用 $\mathbb{P}(B^c) = 1 - A$ 即得。 □

定理 3.3（相同准确率的紧确界） 对任意奇数 K 和 $p \in [0,1]$，

$$\boxed{A_-(K,p) = \max\Big\{0,\ \frac{2Kp - K + 1}{K+1}\Big\}, \qquad A_+(K,p) = \min\Big\{1,\ \frac{2Kp}{K+1}\Big\}.}$$

两个界都能由可交换分布取到。

证明. *界的成立。*由期望的线性性（不需要独立性），$\mathbb{E}[S] = Kp$。代入引理 3.2，

$$A \;\geq\; \frac{Kp - (m-1)}{K - m + 1} = \frac{2Kp - K + 1}{K+1}, \qquad A \;\leq\; \frac{Kp}{m} = \frac{2Kp}{K+1},$$

这里用了 $m - 1 = (K-1)/2$ 和 $K - m + 1 = m = (K+1)/2$。再结合 $0 \leq A \leq 1$ 即得两个界。

可达性。$K = 1$ 时 $m = 1$，$A = p$，而两个公式也都等于 p。下设 $K \geq 3$，此时 $m - 1 \geq 1$，$K - m = m - 1 \geq 1$。

- 下界，情形 $Kp \leq m-1$：取 $w_{m-1} = Kp/(m-1) \in [0,1]$，$w_0 = 1 - w_{m-1}$。则 $\mathbb{E}[S] = Kp$，且 $S \leq m-1$ 恒成立，故 $A = 0$。
- 下界，情形 $Kp > m - 1$：令 $a = \frac{Kp-(m-1)}{K-m+1}$。由 $p \leq 1$ 得 $a \in (0,1]$。取 $w_K = a$，$w_{m-1} = 1 - a$，则 $\mathbb{E}[S] = aK + (1-a)(m-1) = Kp$，且 $A = w_K = a$。
- 上界，情形 $Kp \leq m$：取 $w_m = Kp/m$，$w_0 = 1 - Kp/m$，则 $\mathbb{E}[S] = Kp$，$A = Kp/m$。
- 上界，情形 $Kp > m$：令 $\theta = \frac{Kp-m}{K-m} \in (0,1]$，取 $w_K = \theta$，$w_m = 1 - \theta$，则 $\mathbb{E}[S] = \theta K + (1-\theta)m = Kp$，且 $S \geq m$ 恒成立，故 $A = 1$。

在每种情形下，由定义 3.1 后的说明，各分类器的准确率都是 $\mathbb{E}[S]/K = p$。 □

推论 3.4 设 $1/2 < p < 1$。则 $A_-(K,p) = (2p-1) + \dfrac{2(1-p)}{K+1}$ 关于奇数 K 严格递减，且

$$\lim_{K\to\infty} A_-(K,p) = 2p - 1 < p.$$

另一方面，当 $K \geq 1/(2p-1)$ 时 $A_+(K,p) = 1$。

证明. $\frac{2Kp-K+1}{K+1} = \frac{(2p-1)(K+1)+2-2p}{K+1}$，且当 $p > 1/2$ 时该值为正。A_+ 的结论由 $2Kp \geq K+1 \iff K(2p-1) \geq 1$ 得到。 □

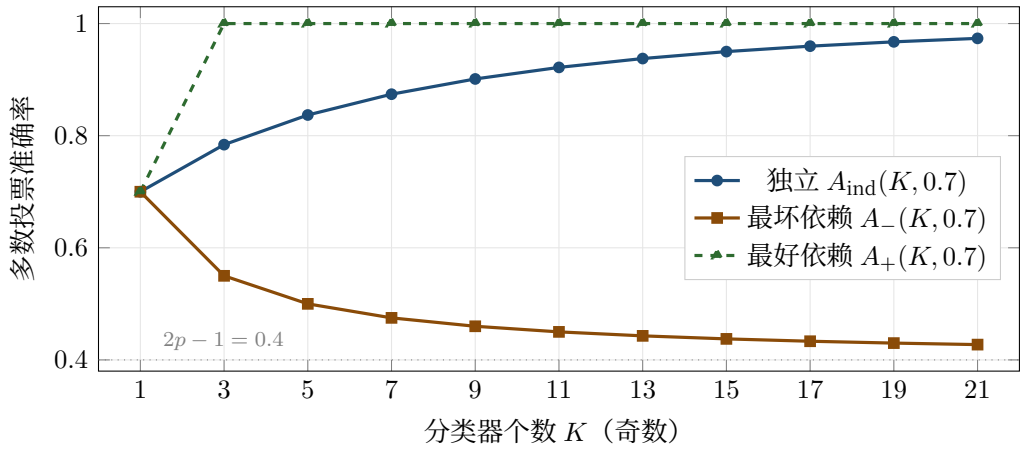


图 1 $p = 0.7$ 时三种情形下多数投票准确率随 K 的变化。独立时趋于 1；依赖结构任意时，最坏情况随 K 单调下降并趋于 $2p-1$。

注 3.5（最坏情况的结构） 定理 3.3 的极值分布说明：当 $0 < A_- < 1$ 时，最坏情况下正确票要么集中在“全体都对”的样本上，要么分散为“恰好差一票”（$S = m-1$）的样本。前者在多出的 $K-m$ 票上被浪费，后者恰好全部失败。当 $A_+ < 1$ 时，最好情况则相反：成功样本恰好以 m 票通过，不浪费任何正确票。截断的情形（$A_- = 0$ 或 $A_+ = 1$）见证明中的对应构造。

4 Part I(c)：不同准确率、依赖任意

记 $p_{(1)} \geq p_{(2)} \geq \cdots \geq p_{(K)}$ 为准确率的降序排列，$p_{[1]} \leq p_{[2]} \leq \cdots \leq p_{[K]}$ 为升序排列。

定理 4.1（任意边缘准确率的紧确界） 对任意奇数 K 和 $p \in [0,1]^K$，

$$A_-(p) = \max\Big\{0,\ \max_{m\leq j\leq K} \frac{\sum_{i=1}^{j} p_{(i)} - (m-1)}{j-m+1}\Big\}, \qquad A_+(p) = \min\Big\{1,\ \min_{m\leq j\leq K} \frac{\sum_{i=1}^{j} p_{[i]}}{j-m+1}\Big\}.$$

两个界都能取到。当 $p_i \equiv p$ 时，下界中的最大值在 $j = K$ 处取到，上界中的最小值也在 $j = K$ 处取到，从而退化为定理 3.3。

证明需要一个构造性引理。

引理 4.2（系统抽样引理） 设 $x \in [0,1]^K$，$s = \sum_i x_i$。则存在随机向量 $Z \in \{0,1\}^K$ 使得 $\mathbb{E}[Z_i] = x_i$ 对所有 i 成立，且几乎必然有 $\sum_i Z_i \in \{\lfloor s \rfloor, \lceil s \rceil\}$。特别地，对整数 c：若 $s \leq c$，则 $\sum_i Z_i \leq c$；若 $s \geq c$，则 $\sum_i Z_i \geq c$。

证明. 令 $c_0 = 0$，$c_i = x_1 + \cdots + x_i$，$U \sim \mathrm{Unif}[0,1)$。对 $a \le b$ 定义 $N(a,b)$ 为随机格点集 $U + \mathbb{Z}$ 落入半开区间 $[a,b)$ 的点数。由于 $U + n \ge a \iff n \ge a - U$，有

$$N(a,b) = \lceil b - U \rceil - \lceil a - U \rceil.$$

令 $Z_i = N(c_{i-1}, c_i)$。下面验证三点。

(a) $Z_i \in \{0,1\}$：区间 $[c_{i-1}, c_i)$ 是半开的，长度为 $x_i \le 1$，而格点间距为 1，所以区间内至多有一个格点。

(b) $\mathbb{E}[Z_i] = x_i$：对任意实数 $t = k + f$（$k \in \mathbb{Z}$，$f \in [0,1)$），若 $U < f$ 则 $\lceil t - U \rceil = k + 1$，否则为 k。因此 $\mathbb{E}\lceil t - U \rceil = k + f = t$，从而 $\mathbb{E}N(a,b) = b - a$。

(c) 总和：$\sum_i Z_i = N(0,s) = \lceil s - U \rceil - \lceil -U \rceil = \lceil s - U \rceil$。因为 $s - U \in (s-1, s]$，所以 $\lceil s - U \rceil \in \{\lfloor s \rfloor, \lceil s \rceil\}$。

最后一句结论由 $\lceil s \rceil \le c$（当 $s \le c$）和 $\lfloor s \rfloor \ge c$（当 $s \ge c$）得到。 □

引理 4.3（下界条件的等价形式） 对 $a \in [0,1]$，下列两条等价：

(a) 对所有 $m \le j \le K$，$\sum_{i=1}^{j} p_{(i)} \le (m-1) + (j - m + 1)a$；

(b) $\sum_{i=1}^{K} (p_i - a)_+ \le (m-1)(1-a)$，其中 $(x)_+ = \max\{x, 0\}$。

并且满足 (a) 的 $a \in [0,1]$ 恰好构成区间 $[a^*, 1]$，其中 a^* 为定理 4.1 中下界的右端。

证明. 对任意 $T \subseteq [K]$，记条件 C_T：$\sum_{i \in T} (p_i - a) \le (m-1)(1-a)$。当 $|T| = j \ge m$ 时，C_T 等价于 $\sum_{i \in T} p_i \le (m-1) + (j-m+1)a$；在所有大小为 j 的 T 中，左边在前 j 大处最大。所以 (a) 等价于“C_T 对所有 $|T| \ge m$ 成立”。当 $|T| \le m-1$ 时，C_T 总成立，因为每项 $p_i - a \le 1 - a$。所以 (a) 等价于“C_T 对所有 T 成立”，即 $\max_T \sum_{i \in T} (p_i - a) \le (m-1)(1-a)$。而左边的最大值在 $T = \{i : p_i > a\}$ 处取到，等于 $\sum_i (p_i - a)_+$，这就是 (b)。

(a) 中第 j 个条件等价于 $a \ge c_j := \frac{\sum_{i \le j} p_{(i)} - (m-1)}{j - m + 1}$。又 $c_j \le \frac{j - (m-1)}{j-m+1} = 1$，所以 $[0,1]$ 中满足 (a) 的 a 恰为 $[\max\{0, \max_j c_j\}, 1] = [a^*, 1]$。 □

引理 4.4 $a^* \le p_{(m)}$。

证明. 取 $a = p_{(m)}$ 检验条件 (b)：满足 $p_i > p_{(m)}$ 的指标至多有 $m-1$ 个，且每个 $(p_i - p_{(m)})_+ \le 1 - p_{(m)}$，所以 (b) 成立。由引理 4.3，$p_{(m)} \in [a^*, 1]$。 □

定理 4.1 的证明. *下界成立。* 任取 $|T| = j \ge m$，令 $S_T = \sum_{i \in T} Z_i$。在 $B = \{S \ge m\}$ 上 $S_T \le j$；在 B^c 上 $S_T \le S \le m - 1$。所以 $S_T \le j \mathbf{1}_B + (m-1)\mathbf{1}_{B^c}$，取期望得

$$\sum_{i \in T} p_i \le (m-1) + (j - m + 1)A.$$

取 T 为前 j 大的分类器，再对 j 取最大，即得 $A \ge a^*$。

下界可达。 令 $a = a^*$。由引理 4.3，(b) 在 a 处成立。

- 若 $a=0$：(b) 给出 $\sum_i p_i \le m-1$。对 $x=p$ 用引理 4.2，得到边缘为 p 且 $S\le m-1$ 几乎必然成立的 Z，于是 $A=0$。
- 若 $a=1$：存在 $j\ge m$ 使 $\sum_{i\le j} p_{(i)} = j$，从而 $\sum_i p_i \ge m$。用引理 4.2 得 $S\ge m$ 几乎必然成立，于是 $A=1$。
- 若 $0<a<1$：令

$$u_i = \frac{(p_i-a)_+}{1-a}, \qquad v_i = \frac{\min\{p_i,a\}}{a}.$$

由 $p_i\le 1$ 知 $u_i, v_i \in [0,1]$。由 (b) 得 $\sum_i u_i \le m-1$。由引理 4.4，至少有 m 个指标满足 $p_i \ge a$，对这些指标 $v_i=1$，故 $\sum_i v_i \ge m$。由引理 4.2，存在 $Z^{(0)}$ 使其边缘为 u 且 $\sum_i Z_i^{(0)} \le m-1$，也存在 $Z^{(1)}$ 使其边缘为 v 且 $\sum_i Z_i^{(1)} \ge m$。取与它们独立的 $\xi\sim\mathrm{Bernoulli}(a)$，令 $Z=\xi Z^{(1)}+(1-\xi)Z^{(0)}$。则

$$\mathbb{P}(Z_i=1) = (1-a)u_i + a v_i = (p_i-a)_+ + \min\{p_i,a\} = p_i, \qquad \mathbb{P}(S\ge m) = \mathbb{P}(\xi=1) = a.$$

*上界。*令 $W_i = 1-Z_i$，其边缘为 $1-p_i$。由于 $K-S\ge m \iff S\le K-m = m-1$，事件 $\{S\ge m\}$ 与 $\{\sum_i W_i \ge m\}$ 互补。所以

$$A_+(p) = 1 - A_-(1-p_1,\dots,1-p_K).$$

$1-p$ 的前 j 大之和等于 $j-\sum_{i\le j} p_{[i]}$。代入下界公式化简：

$$1 - \frac{j-\sum_{i\le j}p_{[i]} - (m-1)}{j-m+1} = \frac{\sum_{i\le j} p_{[i]}}{j-m+1},$$

即得上界公式，其可达性由下界的可达性得到。

退化到相同准确率。$p_i\equiv p$ 时，

$$c_j = \frac{jp-(m-1)}{j-m+1} = p - \frac{(m-1)(1-p)}{j-m+1}, \qquad \frac{jp}{j-m+1} = p + \frac{(m-1)p}{j-m+1}.$$

前者关于 j 不减，后者关于 j 不增，所以两者的最值都在 $j=K$ 处取到。 □

例 4.5 设 $K=3$，$p=(0.95,0.95,0.3)$。则 $j=2$ 项为 $0.95+0.95-1=0.9$，$j=3$ 项为 $(2.2-1)/2=0.6$，所以 $A_-=0.9$。直观解释：两个强分类器同时正确的概率至少为 0.9（Bonferroni 不等式），而只要它们同时正确，多数投票就一定正确。可见“最强的 j 个分类器”这一项确实可能主导下界。

注 4.6 引理 4.2 的构造就是抽样调查中的系统抽样。它比用“多面体 $\{x\in[0,1]^K : \sum_i x_i \le c\}$ 是整数多面体”来论证更直接，而且给出了可以实际采样的极值分布。

5 Part II：给定两两相关系数

5.1 从相关系数到两两联合概率

设 $0<p_i<1$（否则相关系数无定义）。对 Bernoulli 变量有 $\mathbb{E}[Z_iZ_j] = \mathbb{P}(Z_i=Z_j=1)$，所以

$$r_{ij} := \mathbb{P}(Z_i=Z_j=1) = p_ip_j + \rho_{ij}\sqrt{p_i(1-p_i)p_j(1-p_j)}.$$

给定 (p,ρ) 等价于给定 (p,r)。记 $\mathcal{P}(p,r)$ 为满足这些一阶与二阶约束的分布全体，$A_{\min} = \min_{\pi\in\mathcal{P}(p,r)} \mathbb{P}_\pi(S \geq m)$，$A_{\max}$ 类似。

5.2 三个分类器：完整闭式解

引理 5.1（指示函数恒等式） 当 $K = 3$ 时，

$$\mathbf{1}\{S \geq 2\} = Z_1Z_2 + Z_1Z_3 + Z_2Z_3 - 2Z_1Z_2Z_3.$$

因此，记 $R = r_{12} + r_{13} + r_{23}$，$t = \mathbb{P}(Z_1 = Z_2 = Z_3 = 1)$，有 $A = R - 2t$。

证明. 逐一检查：$S \leq 1$ 时两边都为 0；$S = 2$ 时右边恰有一项乘积为 1，等于 1；$S = 3$ 时右边为 $3 - 2 = 1$。取期望即得 $A = R - 2t$。 □

定理 5.2（$K = 3$ 的一般闭式解） 设 $K = 3$，给定 $p \in (0,1)^3$ 和 r_{12}, r_{13}, r_{23}。令

$$\begin{aligned} L &= \max\{0,\ r_{12} + r_{13} - p_1,\ r_{12} + r_{23} - p_2,\ r_{13} + r_{23} - p_3\}, \\ U &= \min\{r_{12},\ r_{13},\ r_{23},\ 1 - p_1 - p_2 - p_3 + R\}. \end{aligned}$$

则：

(i) $\mathcal{P}(p,r) \neq \emptyset$ 当且仅当 $L \leq U$；

(ii) 当 $\mathcal{P}(p,r) \neq \emptyset$ 时，t 的可能取值恰为 $[L,U]$，多数投票准确率的可能取值恰为整个区间

$$\boxed{A \in [\,R - 2U,\ R - 2L\,].}$$

证明. 任一分布 $\pi \in \mathcal{P}(p,r)$ 的 8 个格点概率由 t 唯一决定（容斥 / Möbius 反演）：

$$\begin{aligned} \pi(111) &= t, & \pi(000) &= 1 - p_1 - p_2 - p_3 + R - t, \\ \pi(110) &= r_{12} - t, & \pi(100) &= p_1 - r_{12} - r_{13} + t, \\ \pi(101) &= r_{13} - t, & \pi(010) &= p_2 - r_{12} - r_{23} + t, \\ \pi(011) &= r_{23} - t, & \pi(001) &= p_3 - r_{13} - r_{23} + t. \end{aligned}$$

例如 $\pi(110) = \mathbb{P}(Z_1 = Z_2 = 1) - \mathbb{P}(Z_1 = Z_2 = Z_3 = 1)$。反过来，对任意实数 t，这 8 个数之和恒等于 1，且其一阶、二阶边缘恰为 p 与 r。所以它们构成 $\mathcal{P}(p,r)$ 中的分布，当且仅当它们全部非负，即 $L \leq t \leq U$。这证明了 (i) 以及 t 的可行范围。由引理 5.1，$A = R - 2t$ 是 t 的严格递减仿射函数，从而 (ii) 成立。 □

推论 5.3（对称情形） 设 $p_i \equiv p \in (0,1)$，$\rho_{ij} \equiv \rho$，$r = p^2 + \rho p(1-p)$。则：

(i) 参数相容当且仅当

$$\max\{0,\ p - \tfrac{1}{3},\ 2p - 1\} \ \leq\ r\ \leq\ p. \tag{1}$$

用 ρ 表示，$\rho \le 1$ 总成立，下限为

$$\rho \;\ge\; \rho_{\min}(p) = \begin{cases} -\dfrac{p}{1-p}, & 0 < p \le \frac{1}{3}, \\[2mm] \dfrac{p - \frac{1}{3} - p^2}{p(1-p)}, & \frac{1}{3} \le p \le \frac{2}{3}, \\[2mm] -\dfrac{1-p}{p}, & \frac{2}{3} \le p < 1. \end{cases}$$

(ii) 多数投票准确率的精确范围为

$$\boxed{A_{\min}(p,\rho) = \max\{r,\; 6p - 3r - 2\}, \qquad A_{\max}(p,\rho) = \min\{3r,\; 2p - r\}.}$$

(iii) 取到界的分布可以选为可交换分布 $\sum_s q_s \mu_s$，其中

$$q_0 = 1 - 3p + 3r - t, \quad q_1 = 3p - 6r + 3t, \quad q_2 = 3r - 3t, \quad q_3 = t,$$

下界取 $t = U = \min\{r, 1 - 3p + 3r\}$，上界取 $t = L = \max\{0, 2r - p\}$。

证明. 代入定理 5.2：$L = \max\{0, 2r - p\}$，$U = \min\{r, 1 - 3p + 3r\}$。

(i) $L \le U$ 等价于以下四个不等式同时成立：$0 \le r$；$0 \le 1 - 3p + 3r$（即 $r \ge p - \frac{1}{3}$）；$2r - p \le r$（即 $r \le p$）；$2r - p \le 1 - 3p + 3r$（即 $r \ge 2p - 1$）。ρ 的形式由 $r = p^2 + \rho p(1-p)$ 得到：$r \le p \iff \rho \le 1$；下限中的三项分别在 $p \le \frac{1}{3}$、$\frac{1}{3} \le p \le \frac{2}{3}$、$p \ge \frac{2}{3}$ 时最大。

(ii) $A_{\min} = 3r - 2U = \max\{r,\; 3r - 2(1 - 3p + 3r)\} = \max\{r, 6p - 3r - 2\}$；$A_{\max} = 3r - 2L = \min\{3r,\; 2p - r\}$。

(iii) 对可交换分布，$\mathbb{E}S = q_1 + 2q_2 + 3q_3 = 3p$，$\mathbb{E}\binom{S}{2} = q_2 + 3q_3 = 3r$，再由 $\sum q_s = 1$ 和 $q_3 = t$ 解出 q。由定义 3.1，其边缘为 $\mathbb{E}S/3 = p$，两两联合概率为 $\mathbb{E}[S(S-1)]/6 = \mathbb{E}\binom{S}{2}/3 = r$。 □

注 5.4 等相关矩阵半正定只要求 $\rho \ge -\frac{1}{2}$。推论 5.3(i) 表明，Bernoulli 变量还受离散取值的约束：除 $p \in \{\frac{1}{3}, \frac{2}{3}\}$ 外，可行的 ρ 下限都严格大于 $-\frac{1}{2}$。例如 $p = \frac{1}{2}$ 时 $\rho \ge -\frac{1}{3}$。

例 5.5（相同准确率、两两不相关，但集成准确率不同） 取 $p = 0.6$，$\rho = 0$，则 $r = 0.36$，$R = 1.08$。推论 5.3 给出

$$A_{\min} = \max\{0.36,\; 0.52\} = 0.52, \qquad A_{\max} = \min\{1.08,\; 0.84\} = 0.84.$$

三个具体分布如下（均为可交换分布 $\sum_s q_s \mu_s$，即给定 $S = s$ 时均匀随机选出 s 个正确的分类器）：

情形	q_0	q_1	q_2	$q_3 = t$	$A = q_2 + q_3$
最差（$t = U = 0.28$）	0	0.48	0.24	0.28	0.52
独立	0.064	0.288	0.432	0.216	0.648
最好（$t = L = 0.12$）	0.16	0	0.72	0.12	0.84

三者都满足 $\mathbb{E}S = 1.8$、$\mathbb{E}\binom{S}{2} = 1.08$。由于取的是可交换分布，每个分类器的准确率都是 0.6，任意两个分类器都不相关。需要强调的是：只给出 q_s 并不够，必须指明“均匀选取”这一构造。例如 $S = 1$ 时若总让分类器 1 正确，各分类器的边缘就不再相等。

命题 5.6（与 Part I 的一致性） $K = 3$ 时，

$$\min_{\rho\ \text{可行}} A_{\min}(p,\rho) = A_-(3,p) = \max\Big\{0, \frac{3p-1}{2}\Big\},$$
$$\max_{\rho\ \text{可行}} A_{\max}(p,\rho) = A_+(3,p) = \min\Big\{1, \frac{3p}{2}\Big\}.$$

证明. *最小值。* $\max\{r, 6p-3r-2\}$ 关于 r 先降后升，两段在 $r^* = (3p-1)/2$ 处相交，交点值为 $(3p-1)/2$。若 $p \ge \frac{1}{3}$，可以验证 r^* 满足 (1)：$r^* \ge p - \frac{1}{3} \iff p \ge \frac{1}{3}$，$r^* \ge 2p-1 \iff p \le 1$，$r^* \le p \iff p \le 1$。故最小值为 $(3p-1)/2$。若 $p < \frac{1}{3}$，取 $r = 0$（可行），得 $\max\{0, 6p-2\} = 0$。

最大值。 $\min\{3r, 2p-r\}$ 在 $r = p/2$ 处取到峰值 $3p/2$。若 $p \le \frac{2}{3}$，$r = p/2$ 可行，最大值为 $3p/2$。若 $p > \frac{2}{3}$，可行下限为 $r_0 = 2p-1 > p/2$，此处 $\min\{3r_0, 2p-r_0\} = 2p - r_0 = 1$。

两种情形都与定理 3.3 在 $K = 3$ 时的值一致。 □

5.3 一般 K：线性规划

定理 5.7（线性规划表述） 对任意奇数 K，令 $x_z = \pi(z)$（$z \in \{0,1\}^K$），$c_z = \mathbf{1}\{\sum_i z_i \ge m\}$。则

$$A_{\min} = \min_x \sum_z c_z x_z, \qquad A_{\max} = \max_x \sum_z c_z x_z,$$

约束为 $\sum_z x_z = 1$；$\sum_z z_i x_z = p_i$（$\forall i$）；$\sum_z z_i z_j x_z = r_{ij}$（$\forall i<j$）；$x_z \ge 0$。可行域是有界多面体，若非空则两个最优值都能取到；可行域非空当且仅当 (p,r) 能由某个 Bernoulli 联合分布实现。

证明. 目标函数与约束都是 x 的线性函数，可行域含于概率单纯形，因而是紧的。线性函数在非空紧集上取到最值。 □

命题 5.8（对称情形的约化） 设 $p_i \equiv p$，$r_{ij} \equiv r$。则 $A_{\min}, A_{\max}$ 分别等于下面关于 $q = (q_0, \dots, q_K)$ 的线性规划的最优值：

$$\min\,/\,\max \sum_{s \ge m} q_s \quad \text{s.t.} \quad \sum_s q_s = 1, \quad \sum_s s\, q_s = Kp, \quad \sum_s \binom{s}{2} q_s = \binom{K}{2} r, \quad q \ge 0.$$

最优值可在至多 3 个分量非零的 q 处取到。

证明. 任一 $\pi \in \mathcal{P}(p,r)$ 诱导出 S 的分布 q，且 $\mathbb{E}S = Kp$，$\mathbb{E}\binom{S}{2} = \sum_{i<j} r_{ij} = \binom{K}{2} r$，$A = \sum_{s \ge m} q_s$，所以 q 可行且目标值相同。反之，任一可行 q 给出可交换分布 $\sum_s q_s \mu_s$。由定义 3.1，它的边缘为 $\mathbb{E}S/K = p$，两两联合概率为 $\mathbb{E}[S(S-1)]/(K(K-1)) = r$，因而属于 $\mathcal{P}(p,r)$，并且目标值相同。所以两个问题的可达值集合相同。约化后的问题是只有 3 个等式约束的标准型线性规划，其基本最优解至多有 3 个非零分量。 □

表 1 给出了用命题 5.8 计算的结果。$K \le 11$ 的各项已与完整的 2^K 变量线性规划逐一对照，差值小于 10^{-11}。

	$p=0.6,\ \rho=0$			$p=0.6,\ \rho=0.2$	
K	$A_{\min}$	独立	$A_{\max}$	$A_{\min}$	$A_{\max}$
3	0.5200	0.6480	0.8400	0.4080	0.7920
5	0.4667	0.6826	0.9200	0.3440	0.8560
7	0.4800	0.7102	0.9600	0.3120	0.8880
9	0.4800	0.7334	0.9840	0.2928	0.9072
11	0.5000	0.7535	1.0000	0.2800	0.9200
21	0.5800	0.8256	1.0000	0.2509	0.9491

表 1 对称情形下给定 (p,ρ) 时多数投票准确率的精确范围（数值解，保留 4 位小数）。即使所有两两相关系数都为 0，$K=5$ 时的最坏准确率 0.4667 仍低于单个分类器的 0.6。

6 与已有文献的关系

本节说明哪些结论属于已知结果。表 2 中“一致”的含义是：已将文献中的公式或数值与本文公式做过数值比对。

本文结论	已有文献	关系
定理 2.2	Condorcet 陪审团定理 [1]；增量公式见 [2]（式 7）	经典结论
定理 3.3	Kuncheva 等 [4] 的 pattern of failure / success；Zaigraev 与 Kaniovski [8]（定理 1）	已知，公式一致
定理 4.1	Matan [6] 的上下界（证明见 [5] 附录 4.A.1）；取补集后为 Rüger [7] 的“n 个事件中至少 k 个发生”的最大概率	已知，与 Matan 公式在随机数据上逐一相等
定理 5.2、推论 5.3	Kaniovski [9] 用线性规划数值求出同一问题 $n=3$ 时的上下界（其表 2）	问题已知；闭式解与其全部 6 组数值一致
推论 5.3(i)	Bernoulli 相关矩阵相容性的一般理论 [15]	一般框架已知
定理 5.7	Narasimhamurthy [10, 11]；Kaniovski [9] 第 6 节（约束与本文逐条相同）	已知
命题 5.8	Prékopa 的二项矩问题 [12, 13]；闭式界见 Boros 与 Prékopa [14]	已知框架的特例

表 2 本文结论与已有文献的对应关系。

据此，本文在数学上的新意有限，比较合理的定位是：(1) 对已知结论给出统一、自包

含、构造性的证明（如引理 4.2 的系统抽样构造）；(2) 对 Kaniovski [9] 用线性规划数值计算的 $K = 3$ 问题给出显式闭式解、相容性条件和极值分布。其中对称情形很可能是 Boros 与 Prékopa [14] 二项矩闭式界的特例（未能逐项比对原文），一般参数的定理 5.2 则超出了二项矩框架；(3) 把分类器集成、陪审团定理和概率界三条文献线联系起来。

核查的局限。 Rüger [7]、Boros 与 Prékopa [14]、Narasimhamurthy [11] 只核对了摘要；Matan [6] 的公式来自 Kuncheva 的教材 [5] 及课程讲义转述；[9, 8] 的定理与表格编号依据作者主页上的预印本，正式发表版本的编号可能不同。

7 结论汇总

问题	结果	位置
独立、相同 p	二项公式；增量 $\binom{2r+1}{r}p^{r+1}q^{r+1}(2p-1)$；极限 $1, \frac{1}{2}, 0$	定理 2.1, 2.2
依赖任意、相同 p	$A_- = \max\{0, \frac{2Kp-K+1}{K+1}\}$，$A_+ = \min\{1, \frac{2Kp}{K+1}\}$，紧确	定理 3.3
K 增大时的最坏情况	$\frac{1}{2} < p < 1$ 时严格递减，极限 $2p-1$	推论 3.4
依赖任意、不同 p_i	排序部分和公式，紧确，可构造	定理 4.1
两两相关是否足够	不足够；$p = 0.6, \rho = 0$ 时 $A \in [0.52, 0.84]$	例 5.5
$K = 3$、一般参数	$A \in [R-2U,\ R-2L]$，相容 $\iff L \le U$	定理 5.2
$K = 3$、对称参数	$[\max\{r, 6p-3r-2\},\ \min\{3r, 2p-r\}]$	推论 5.3
一般 K	2^K 变量线性规划；对称时降为 $K+1$ 变量	定理 5.7，命题 5.8

参考文献

[1] M. de Condorcet. *Essai sur l'application de l'analyse à la probabilité des décisions rendues à la pluralité des voix*. Paris, 1785.

[2] H. Shteingart et al. Majority voting and the Condorcet's jury theorem. arXiv:2002.03153, 2020.

[3] W. Hoeffding. Probability inequalities for sums of bounded random variables. *Journal of the American Statistical Association*, 58(301):13–30, 1963.

[4] L. I. Kuncheva, C. J. Whitaker, C. A. Shipp, R. P. W. Duin. Limits on the majority vote accuracy in classifier fusion. *Pattern Analysis and Applications*, 6(1):22–31, 2003.

[5] L. I. Kuncheva. *Combining Pattern Classifiers: Methods and Algorithms*, 2nd ed. Wiley, 2014.

[6] O. Matan. On voting ensembles of classifiers (extended abstract). AAAI-96 Workshop on Integrating Multiple Learned Models, 1996.

[7] B. Rüger. Das maximale Signifikanzniveau des Tests „Lehne H_0 ab, wenn k unter n gegebenen Tests zur Ablehnung führen“. *Metrika*, 25:171–178, 1978.

[8] A. Zaigraev, S. Kaniovski. Bounds on the competence of a homogeneous jury. *Theory and Decision*, 72(1):89–112, 2012.

[9] S. Kaniovski. Aggregation of correlated votes and Condorcet's jury theorem. *Theory and Decision*, 69(3):453–468, 2010.

[10] A. M. Narasimhamurthy. A framework for the analysis of majority voting. In *Lecture Notes in Computer Science*, vol. 2749. Springer, 2003.

[11] A. Narasimhamurthy. Theoretical bounds of majority voting performance for a binary classification problem. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 27(12):1988–1995, 2005.

[12] A. Prékopa. Boolean–Bonferroni inequalities and linear programming. *Operations Research*, 36(1):145–162, 1988.

[13] A. Prékopa. Sharp bounds on probabilities using linear programming. *Operations Research*, 38(2):227–239, 1990.

[14] E. Boros, A. Prékopa. Closed form two-sided bounds for probabilities that at least r and exactly r out of n events occur. *Mathematics of Operations Research*, 14(2):317–342, 1989.

[15] N. R. Chaganty, H. Joe. Range of correlation matrices for dependent Bernoulli random variables. *Biometrika*, 93(1):197–206, 2006.