# 集成投票的极限

Part I 与 Part II 证明导读（面向初学者）

2026 年 10 月

**这份讲义讲什么**

很多人相信：“把几个还不错的模型放在一起投票，结果一定更好。”这份讲义用三个问题检验这个说法：

1. 如果各个模型**互相独立**，投票确实越来越好吗？（会，这是 Condorcet 陪审团定理。）
2. 如果模型之间可以**任意相关**，只知道每个模型的准确率，投票最差能差到什么程度？
3. 如果再告诉你**每两个模型之间的相关系数**，能不能把投票准确率算准？（不能，差距可能很大。）

**需要的预备知识：**概率、期望、二项分布、相关系数的定义。每节末尾有“要点”框，可以先看要点再读细节。严格的定理与证明见配套文档《严格数学证明》。

## 目录

1 把问题翻译成数学 2

2 独立时：分类器越多越好 2

3 不再假设独立：最坏能有多坏？ 3

4 准确率各不相同时 5

5 Part II：知道两两相关系数也不够 6

6 更多分类器：交给线性规划 8

7 总结 9

# 1 把问题翻译成数学

设想三个分类器判断邮件是否为垃圾邮件。对每封测试邮件，我们只记录每个分类器**判对**（记作 1）还是**判错**（记作 0）：

| 邮件 | 分类器 1 | 分类器 2 | 分类器 3 | 判对的个数 $S$ | 多数投票对吗? |
|---|---|---|---|---|---|
| 1 | 1 | 1 | 0 | 2 | 对 |
| 2 | 0 | 1 | 0 | 1 | 错 |
| 3 | 1 | 1 | 1 | 3 | 对 |
| 4 | 0 | 0 | 1 | 1 | 错 |

**为什么只看“对或错”就够了?** 这是二分类问题，只有两个标签。判对的分类器都投给真实标签，判错的都投给另一个标签。所以真实标签得到 $S$ 票，错误标签得到 $3-S$ 票。多数投票判对，当且仅当 $S \geq 2$。一般地，$K$ 个分类器（$K$ 为奇数）投票时，多数投票判对当且仅当至少有

$$m = \frac{K+1}{2}$$

个分类器判对。

于是我们定义：$Z_i = 1$ 表示第 $i$ 个分类器判对，$p_i = \mathbb{P}(Z_i = 1)$ 是它的准确率，$S = Z_1 + \cdots + Z_K$ 是判对的个数。整个问题的主角是

$$\boxed{\text{集成准确率 } A = \mathbb{P}(S \geq m).}$$

**要点**

集成准确率只取决于“哪些分类器同时判对”的规律，也就是 $(Z_1, \ldots, Z_K)$ 的联合分布。不同的联合分布可以有完全相同的单个准确率，但 $A$ 不同。这是整份讲义的核心。

# 2 独立时：分类器越多越好

## 2.1 三个分类器的计算

如果三个分类器互相独立、准确率都是 $p = 0.7$，那么 $S \sim \mathrm{Bin}(3, 0.7)$：

$$A = \mathbb{P}(S=2) + \mathbb{P}(S=3) = 3 \times 0.7^2 \times 0.3 + 0.7^3 = 0.441 + 0.343 = 0.784.$$

三个 70% 的分类器投票，得到了 78.4% 的准确率。

## 2.2 为什么多加两个会更好?

从 $K$ 个分类器加到 $K+2$ 个，多数门槛从 $m$ 变成 $m+1$。新来的两票只在两种“临界”局面下才会改变结果：

| 原来 $K$ 个中判对的个数 | 原来的结果 | 加两个之后 |
|---|---|---|
| 差一票（$S = m - 1$） | 错 | 两个新的都对 $\Rightarrow$ 变成对（概率 $p^2$） |
| 刚好过半（$S = m$） | 对 | 两个新的都错 $\Rightarrow$ 变成错（概率 $(1-p)^2$） |
| 其他情况 | — | 不变 |

独立时，可以算出“差一票”的概率恰好是“刚好过半”概率的 $\frac{1-p}{p}$ 倍。所以

$$\text{增量} = \mathbb{P}(\text{刚好过半})\left[\tfrac{1-p}{p}\,p^2 - (1-p)^2\right] = \mathbb{P}(\text{刚好过半})\,(1-p)\,(2p-1).$$

只要 $p > 1/2$，增量就是正的。例如 $p = 0.7$ 时从 3 个加到 5 个，增量为 $3 \times 0.7^2 \times 0.3^2 \times 0.4 \approx 0.053$，准确率从 0.784 升到 0.837。

### 2.3 分类器无穷多时

由大数定律，$S/K$ 会集中在 $p$ 附近。$p > 1/2$ 时，“判对的超过一半”以趋于 1 的概率发生，于是 $A \to 1$。Hoeffding 不等式还给出了速度：$1 - A \le e^{-2K(p-1/2)^2}$。$p < 1/2$ 时则相反，$A \to 0$。

**要点**

独立且准确率都相同时，只要每个分类器都好于随机猜测（$p > 1/2$），加分类器就会让投票准确率单调上升，并趋于 1。关键在于**独立**这个假设。（准确率不同时未必如此：一个 0.99 的分类器加上两个独立的 0.6 分类器，投票准确率只有 0.835。）

## 3 不再假设独立：最坏能有多坏？

### 3.1 十封邮件的例子

三个分类器，每个都恰好判对 10 封中的 6 封（$p = 0.6$）。下面两种安排都满足这一点，但投票结果相差很大。

**安排 A（最坏）**

| 邮件 | C1 | C2 | C3 | 投票 |
|---|---|---|---|---|
| 1–4 | ✓ | ✓ | ✓ | 对 |
| 5, 6 | ✓ | × | × | 错 |
| 7, 8 | × | ✓ | × | 错 |
| 9, 10 | × | × | ✓ | 错 |
| 投票准确率 | | | | **0.4** |

**安排 B（最好）**

| 邮件 | C1 | C2 | C3 | 投票 |
|---|---|---|---|---|
| 1–3 | ✓ | ✓ | × | 对 |
| 4–6 | ✓ | × | ✓ | 对 |
| 7–9 | × | ✓ | ✓ | 对 |
| 10 | × | × | × | 错 |
| 投票准确率 | | | | **0.9** |

在安排 A 中，每个分类器都判对 $4 + 2 = 6$ 封；在安排 B 中，每个分类器都判对 $3 + 3 = 6$ 封。单看每个分类器，两种安排完全一样，但投票准确率一个是 40%（比单个分类器还差），一个是 90%。独立时是 64.8%，介于两者之间。

## 3.2 “数票”论证：为什么最坏是 0.4

关键想法是数“判对的票”的总数。

- 10 封邮件 $\times$ 3 个分类器 $\times$ 0.6 = **18 张判对票**，这个总数与分类器之间是否相关无关。
- 投票**失败**的邮件最多只有 1 张判对票（否则就过半了）。
- 投票**成功**的邮件最多有 3 张判对票。

设有 $x$ 封成功，则 $18 \le 3x + 1 \cdot (10 - x)$，解得 $x \ge 4$。所以无论怎样安排，准确率至少是 40%。安排 A 正好把这个不等式变成了等式：成功的邮件“满票”通过，失败的邮件每封都只差一票。

同理，成功的邮件至少要 2 张判对票，所以 $18 \ge 2x$，即 $x \le 9$。最好是 90%，安排 B 正好取到：每封成功邮件都“刚好过半”，一票都不浪费。

**一般公式（$K$ 个分类器，准确率都是 $p$）**

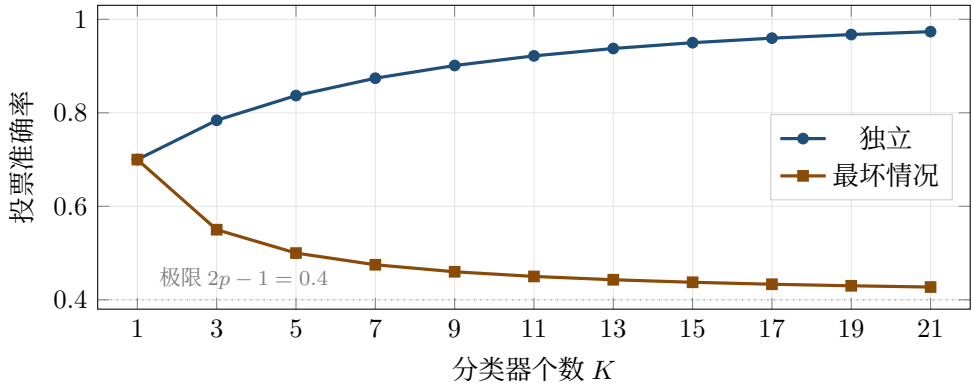
把上面的数票推广：平均每个样本有 $Kp$ 张判对票；失败的样本最多 $m-1$ 张，成功的样本最多 $K$ 张，至少 $m$ 张。于是

$$A_- = \max\left\{0,\ \frac{2Kp - K + 1}{K+1}\right\}, \qquad A_+ = \min\left\{1,\ \frac{2Kp}{K+1}\right\}.$$

这两个界都能取到。最坏情况（当它大于 0 时）用“要么全对，要么恰好差一票”的安排；最好情况（当它小于 1 时）用“要么刚好过半，要么全错”的安排。

## 3.3 分类器越多，最坏情况越糟

把 $p = 0.7$ 代入，比较独立情形和最坏情形：




当 $p > 1/2$ 时，最坏情况可以写成 $A_- = (2p-1) + \frac{2(1-p)}{K+1}$，随 $K$ 增大而下降，极限是 $2p-1$。$p = 0.7$ 时，极限只有 0.4，远低于单个分类器的 0.7。

**这对实践意味着什么**

最坏情况并不是“所有分类器犯同样的错”：完全相同的分类器投票，准确率就是 $p$，既没变好也没变差。最坏情况是一种更“刁钻”的相关结构：在一部分样本上全部判对（多出来的正确票被浪费），在其余样本上恰好差一票而失败。这说明评估集成时不能只看单个准确率，还要看错误在样本上的分布方式。集成的收益来自错误的**多样性**，而不仅仅是模型的数量。

**要点**

只知道单个准确率时，集成准确率可以落在一个区间里的任何位置。区间的两端由“数票”不等式给出，而且都能取到。分类器越多，最坏情况反而越差。

# 4 准确率各不相同时

## 4.1 一个启发性的例子

设三个分类器的准确率为 $(0.95, 0.95, 0.3)$。如果直接套用“所有分类器一起数票”，平均每个样本有 2.2 张判对票，得到 $A \geq (2.2-1)/2 = 0.6$。但其实可以得到更好的下界：只看前两个强分类器，它们同时判对的概率至少是 $0.95 + 0.95 - 1 = 0.9$；而只要它们同时判对，多数投票就一定对。所以 $A \geq 0.9$，而且这正是最坏情况。

启示：数票时不一定要把所有分类器都算进去，挑一组最强的分类器来数可能更好。

## 4.2 计算步骤

**最坏情况的计算方法**

1. 把准确率从大到小排好：$p_{(1)} \geq p_{(2)} \geq \cdots \geq p_{(K)}$。
2. 对每个 $j = m, m+1, \ldots, K$，只对最强的 $j$ 个分类器数票，得到
$$c_j = \frac{p_{(1)} + \cdots + p_{(j)} - (m-1)}{j - m + 1}.$$
3. 最坏准确率 $A_- = \max\{0, c_m, c_{m+1}, \ldots, c_K\}$。

**例：** $K = 5$，$m = 3$，准确率 $(0.9, 0.8, 0.7, 0.6, 0.5)$。

$$c_3 = \frac{2.4 - 2}{1} = 0.4, \qquad c_4 = \frac{3.0 - 2}{2} = 0.5, \qquad c_5 = \frac{3.5 - 2}{3} = 0.5.$$

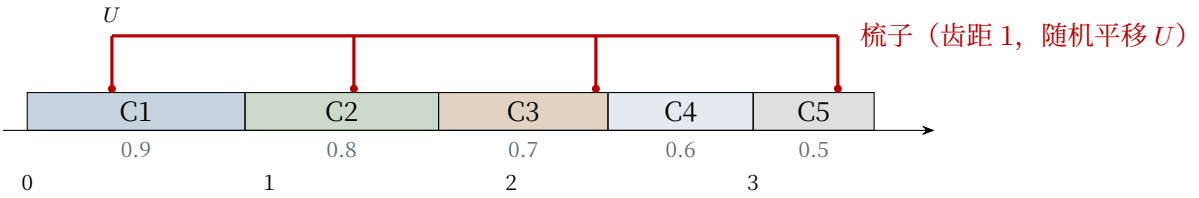
所以 $A_- = 0.5$。最好情况有对称的公式：把准确率从小到大排序，

$$A_+ = \min\Big\{1, \min_{m \leq j \leq K} \frac{p_{[1]} + \cdots + p_{[j]}}{j - m + 1}\Big\}.$$

这个例子的最好情况是 1。

### 4.3 为什么这个界能取到：梳子构造

要证明“最坏真的能这么坏”，需要构造一个具体的联合分布。核心工具是一个巧妙的随机构造，叫**系统抽样**，可以想象成一把梳子：




1. 把长度为 $p_1, p_2, \ldots, p_K$ 的小段首尾相接，排在数轴上。
2. 取一把齿距为 1 的梳子，随机平移一个 $U \sim \mathrm{Unif}[0,1)$ 后放上去。
3. 哪一段被梳齿扎到，对应的分类器就“判对”。

这个构造有两个好性质：

- 每段长度不超过 1，所以最多被扎一次；被扎到的概率恰好等于段长，即每个分类器的准确率恰好是 $p_i$。
- 被扎到的段数，也就是判对的个数，永远是 $\lfloor \sum p_i \rfloor$ 或 $\lceil \sum p_i \rceil$，几乎没有波动。

上图中总长 3.5，所以每次都有 3 个或 4 个分类器判对；图中这一次梳齿扎到 C1、C2、C3、C5，即 4 个分类器判对。最坏情况的构造是把两把梳子按比例混合，但两把梳子用的段长要先改一改：一把的段长是 $u_i = (p_i - a)_+/(1-a)$，总长不超过 $m-1$，保证判对数 $\le m-1$（失败）；另一把的段长是 $v_i = \min\{p_i, a\}/a$，总长至少 $m$，保证判对数 $\ge m$（成功）。这里 $a = A_-$ 是混合比例，混合后每个分类器的准确率恰好回到 $p_i$。以上面的 $K=5$ 为例，$a = 0.5$：以 $\frac{1}{2}$ 的概率五个全对（$v$ 全为 1）；以 $\frac{1}{2}$ 的概率用段长 $(0.8, 0.6, 0.4, 0.2, 0)$ 的梳子，总长恰为 2，所以恰好 2 个判对，投票失败。可以验证分类器 1 的准确率为 $\frac{1}{2} \times 1 + \frac{1}{2} \times 0.8 = 0.9$。

**要点**

准确率不同时，最坏情况等于“挑一组最强的 $j$ 个分类器数票”得到的最好下界。这个下界同样能取到，构造工具是梳子式的系统抽样。

## 5 Part II：知道两两相关系数也不够

### 5.1 相关系数对 0/1 变量意味着什么

对两个 0/1 变量，$\mathbb{E}[Z_i Z_j] = \mathbb{P}(\text{两个都判对})$。由相关系数的定义，

$$r := \mathbb{P}(\text{分类器 } i, j \text{ 都判对}) = p^2 + \rho\, p(1-p).$$

所以知道 $p$ 和 $\rho$，就等于知道了“任意两个同时判对”的概率 $r$。例如 $\rho = 0$ 时 $r = p^2$。

## 5.2 关键恒等式

三个分类器时，多数投票判对的指示函数可以写成

$$\mathbf{1}\{S \geq 2\} = Z_1Z_2 + Z_1Z_3 + Z_2Z_3 - 2Z_1Z_2Z_3.$$

逐一验证：

| 判对个数 $S$ | 两两乘积之和 | $-2Z_1Z_2Z_3$ | 合计 |
|---|---|---|---|
| 0 或 1 | 0 | 0 | 0 |
| 2 | 1 | 0 | 1 |
| 3 | 3 | $-2$ | 1 |

取期望，得到

$$\boxed{A = 3r - 2t, \qquad t = \mathbb{P}(\text{三个都判对}).}$$

$p$ 和 $\rho$ 决定了 $r$，却**没有**决定 $t$。$t$ 是一个“三阶”信息，只看两两关系看不到它。这就是相关系数不够用的根本原因。

## 5.3 25 封邮件的例子

取 $p = 0.6$，$\rho = 0$（两两不相关），于是 $r = 0.36$。下面是两种安排，以及独立情形（独立情形需要 125 封邮件才能凑成整数）：

| 判对模式 | 最坏（25 封） | 独立（125 封） | 最好（25 封） |
|---|---|---|---|
| 三个都对 | 7 | 27 | 3 |
| 恰好两个对（三种模式，每种） | 2 | 18 | 6 |
| 恰好一个对（三种模式，每种） | 4 | 12 | 0 |
| 都不对 | 0 | 8 | 4 |
| 每个分类器判对的比例 | $15/25 = 0.6$ | $75/125 = 0.6$ | $15/25 = 0.6$ |
| 每两个同时判对的比例 | $9/25 = 0.36$ | $45/125 = 0.36$ | $9/25 = 0.36$ |
| **投票准确率** | $\mathbf{13/25 = 0.52}$ | $\mathbf{81/125 = 0.648}$ | $\mathbf{21/25 = 0.84}$ |

以最坏情况为例核对：分类器 1 判对的邮件有“三个都对”7 封、含它的两种“两个对”模式各 2 封、“只有它对”4 封，共 $7+2+2+4 = 15$ 封。分类器 1 和 2 同时判对的有 $7+2 = 9$ 封，比例 $0.36 = 0.6^2$，所以相关系数为 0。

三种安排的单个准确率和两两相关系数完全相同，投票准确率却从 52% 到 84% 不等。

**常见误解**

“两两不相关”不等于“相互独立”。上表最坏和最好的两列都是两两不相关的，但都不独立。只有中间那一列才是真正的独立。

### 5.4 $t$ 能取哪些值?

用 $q_s$ 表示恰好 $s$ 个判对的比例。由“总比例为 1”“平均判对数为 $3p$”“平均判对对数为 $3r$”三个条件，可以把所有 $q_s$ 用 $t$ 表示：

$$q_0 = 1 - 3p + 3r - t, \quad q_1 = 3p - 6r + 3t, \quad q_2 = 3r - 3t, \quad q_3 = t.$$

比例不能是负数，这给出 $t$ 的范围 $\max\{0, 2r-p\} \le t \le \min\{r, 1-3p+3r\}$。代入 $A = 3r - 2t$：

**三个分类器的精确区间**

$$A_{\min} = \max\{r,\ 6p - 3r - 2\}, \qquad A_{\max} = \min\{3r,\ 2p - r\}, \qquad r = p^2 + \rho p(1-p).$$

直观上，最坏情况让“三个都对”尽量多（把判对票浪费在已经稳赢的样本上），最好情况让“三个都对”尽量少。

**不是所有的 $\rho$ 都可能。** 比如三枚“公平硬币”（$p = 0.5$）不可能两两都强烈负相关：如果 1 和 2 总是相反，1 和 3 也总是相反，那么 2 和 3 就总是相同。由 $q_s \ge 0$ 可以算出，$p = 0.5$ 时 $\rho$ 至少是 $-\frac{1}{3}$。这比相关矩阵半正定给出的 $-\frac{1}{2}$ 更严格。

**准确率各不相同时** 做法完全一样：8 种判对模式的概率都可以用 $t$ 表示，令它们非负就得到 $t$ 的范围 $[L, U]$，于是 $A \in [R - 2U, R - 2L]$，其中 $R$ 是三个“两两同时判对”概率之和。

**要点**

准确率加上全部两两相关系数，仍然不能唯一确定投票准确率，因为结果还依赖“三个同时判对”的概率。三个分类器时，这个不确定性可以精确地写成一个区间。

## 6 更多分类器：交给线性规划

$K$ 个分类器有 $2^K$ 种判对模式。把每种模式的概率当作未知数，那么

- 投票准确率是“过半模式”的概率之和，是未知数的**线性**函数；
- “概率之和为 1”“每个分类器的准确率”“每两个同时判对的概率”都是**线性**等式；
- 概率非负是线性不等式。

所以，求投票准确率的最小值和最大值就是一个**线性规划**问题，可以用标准工具数值求解，例如 Python 的 `scipy.optimize.linprog`。

如果所有分类器的准确率相同、两两相关系数也相同，问题还能化简：只需要知道 $S$ 的分布 $q_0, \dots, q_K$，未知数从 $2^K$ 个降到 $K + 1$ 个。下表是 $p = 0.6$、$\rho = 0$ 时的结果：

| $K$ | 最坏 | 独立 | 最好 |
|---|---|---|---|
| 3 | 0.520 | 0.648 | 0.840 |
| 5 | **0.467** | 0.683 | 0.920 |
| 7 | 0.480 | 0.710 | 0.960 |
| 11 | 0.500 | 0.753 | 1.000 |
| 21 | 0.580 | 0.826 | 1.000 |

注意 $K = 5$ 那一行：五个两两*不相关*、准确率 60% 的分类器，多数投票的准确率最低可以只有 46.7%，比单个分类器还差。

## 7 总结

| 已知的信息 | 能说什么 |
|---|---|
| 各自准确率 + 独立 | 准确率可以精确算出；准确率都为 $p > 1/2$ 时越多越好，趋于 1 |
| 只有各自准确率 | 只能确定一个区间；最坏情况可以比单个分类器还差，且随 $K$ 变差 |
| 准确率 + 两两相关 | 区间变窄，但通常仍不是一个点；$K = 3$ 时有闭式区间 |
| 完整的联合分布 | 准确率被唯一确定 |

**四个常见误区**

1. **“不相关就是独立。”**对 0/1 变量，两两不相关不意味着相互独立（见第 5 节的表格）。
2. **“多加模型一定更好。”**在准确率相同且独立时成立；依赖结构不利时，最坏情况下 $K$ 越大越差。
3. **“知道相关系数就能算出集成准确率。”**还需要三阶及更高阶的信息。
4. **“最坏情况只是一个保守的估计。”**这里的最坏情况是紧的，能被具体的联合分布达到。

**这些结论从哪里来？** 独立情形是 18 世纪的 Condorcet 陪审团定理。只知道准确率时的最坏与最好情况，在分类器集成文献中由 Kuncheva 等人（2003）和 Matan（1996）给出，在陪审团理论中由 Zaigraev 与 Kaniovski（2012）给出。给定两两相关系数时用线性规划求上下界的思路见 Kaniovski（2010）。配套文档《引用已有结论的简明证明》给出了完整的引用。